

実世界データの収集

集める現場から、学習可能な資産まで：スケーリング②（学習データの工夫）




Physical AI 基礎編 知能ロボティクス講座
第6回（120分） 担当：高波





高波 亮介

東京大学 松尾・岩澤研究室 博士3年



- 経歴
 - 2022年3月 東京工業大学情報理工学院情報工学系 卒業
 - 2024年3月 東京大学工学系研究科技術経営戦略学専攻 修士課程 卒業
- 研究分野
 - 移動ロボットの構造に応じた強化学習
 - モバイルマニピュレータの遠隔操作インターフェースの開発
 - ナビゲーションのロボット基盤モデルの継続学習
 - ロボット基盤モデル (VLA) のデータ収集システムと継続事前学習



今回のゴール

- 1 ロボットの生データ（rosvbag）の中身と非同期性を理解する
- 2 生データを学習可能なデータセットへ変換する工程（同期・整形・検証）の骨格を理解し、穴埋めコードを完成させて動かせる
- 3 データキュレーションの考え方と主要手法の地図を持ち帰る

前提知識

第3回の模倣学習 $\pi(a|o)$ ・action chunk


Pythonの基礎

ROSのインストールやノード開発の経験は不要 純Pythonでrosvbagを扱います

講義の位置づけと本日の担当範囲



第1回 概要	第2回 活用	第3回 模倣学習	第4回 強化学習	第5回 スケーリング	第6回 データ収集	第7回 実運用
-----------	-----------	-------------	-------------	---------------	--------------	------------



第5回・結論より「律速はデータ × embodiment」／予告「データ収集・プラットフォームの実際」→ 本日の講義

第1回の4つの問いにおける本日の位置

② どう構築するか = 本日の主題	① 何時間必要か → 必要量の見積もり方と 代表的スケール感を§1で
③ どう学習するか（第3～5回で回収済み）	④ どう評価するか：データの検証＝本日 方策の評価＝第7回

LLM：精製の2世代


スケーリング則 [Kaplan+ 2020]・data wall [Muennighoff+ NeurIPS 2023]（第1回・第5回再掲）

第1世代＝規則ベース：C4 [Raffel+ JMLR 2020]

第2世代＝モデルベース分類器：FineWeb-Edu [Penedo+ NeurIPS 2024]（絞った **10%が無フィルタ 350Bに匹敵**）

DCLM・Nemotron-CCの詳細は付録

動画生成：Cosmosの精製パイプライン [NVIDIA 2025]



精製自体が**Blackwell世代GPUで14日**の大規模計算（NeMo Curator）

ロボットへの直結：演習では基盤モデルの視覚特徴（**DINOv2**）で軌道を採点する。動画基盤の軌道埋め込み（Cosmos-Embed1等）はその発展形

データのスケーリングとは、収録時間を増やすことではない。
単位コスト当たりに、同期され、多様で、正しくラベル付けされ、検証可能な軌道をどれだけ作れるか。

ロボットデータに固有の3つの断絶

断絶 1 【§2】

機械的断絶

データが非同期（センサごとに周波数もクロックも違う）→
そもそも (o, a) ペアが存在しない

断絶 2 【§4】

意味的断絶

揃ったデータが「良い」とは限らない
（失敗・冗長・ラベル誤り）

断絶 3 【§5】

信頼の断絶

良いと思ったデータを 検証する
手段 が必要
（可視化・統計・リプレイ）

この3つの断絶を埋める技術が、今日の講義の本題

本日のアジェンダ+データパイプライン全体図



1 収集の現場 18分

2 生データの解剖学 18分

3 データセット化 10分

4 データキュレーション 20分

5 可視化と検証とリプレイ 8分

6 演習（Colab） 30分

演習：「汚れた」生データを、学習チームに納品できるデータセットへ — 全工程を自分の手で一周

1 収集の現場：規模、コスト、歩留まり

デバイスの「紹介」は前回まで。今日は「運用」の話

2 生データの解剖学

3 データセット化

4 データキュレーション

5 可視化と検証とリプレイ

6 演習（Colab）

7 まとめ

収集手段を工程の視点で比較する



手段	スループット	得られる信号	後処理の負荷	主な歩留まり要因
leader-follower ALOHA等	低 実機1台=1人	関節・グリッパが直接	小 同期のみ	疲労・失敗テイク
VR teleop	低～中	retarget後の指令	中 retarget検証	遅延・酔い・熟練
UMI系 handheld	高 実機不要・多拠点並列	映像＋ SLAM推定 のEE pose	大 SLAM・幅推定・整形	SLAM破綻・遮蔽
egocentric Aria / Vision Pro	最高 日常が全部データ	映像＋ (機器次第で) 手姿勢	最大 行動ラベルが無い	姿勢推定誤り・ embodiment gap


スループットと後処理負荷はトレードオフー 収集がスケールするほど品質管理の比重が上がる

※表中のSLAM（自己位置推定）はスライド11で補足

スループットの現実を数字で見る



収集時間（対数軸）



対比：Ego4D 3,670h（人の日常）／HowTo100M 136Mクリップ（Web）



実機teleopの数百時間は、従来の研究室・学術連携型収集で多く見られる規模。1万時間の壁を越えたのは
handheld系と商用フリート

出典）Khazatsky+ RSS 2024（DROID）／Zheng+ 2026（EgoScale）／Generalist 2025（GEN-0）／Grauman+ CVPR 2022（Ego4D）／Miech+ ICCV 2019（HowTo100M）

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

用語の補足：SLAM（自己位置推定と地図作成）

SLAM=Simultaneous Localization and Mapping。カメラやIMUの入力から、「自分（カメラ）がどう動いたか」という6自由度姿勢の軌跡と周囲の地図を同時に推定する技術。



本講座での位置づけ

第2回：ナビゲーションの道具として名前だけ登場

本日：手持ち収集デバイスの「行動ラベル」を作る道具

UMI=映像とIMUからグリッパの軌跡を推定

EgoDex・Aria=デバイス内SLAMで頭部と手の軌跡を推定

弱点（次スライド以降の伏線）

特徴点の追跡に頼るため、**無地の壁、動きブレ、遮蔽、動く物体**で推定が破綻する

関節エンコーダの無いデバイスでは、SLAMが行動ラベルの製造機になる

ケース① UMI : 生データは「GoProのMP4一本」

GoPro 1本の MP4

魚眼映像

IMU


グリップ幅
マーカ

すべてが1ファイルに写り込む [Chi+ RSS 2024]


設計の意味：複数デバイス間の 分散同期問題をハードウェア設計で消した

→ §2の伏線：「同期は収集デバイス設計の問題でもある」

副次効果：MP4一本なので共有・分散収集が容易
(ネットで送れる) → 多拠点化の土台



補足：TRI LBMもUMIデータを活用（第5回参照）



出典) Chi+ RSS 2024 (UMI)


UMIの処理パイプラインと歩留まり



歩留まりの現実：SLAMは無地の壁・動的シーン・遮蔽で破綻
→ 破綻テイクの検出・除去が収集直後の必須工程
(=最初のキュレーション)

さらに「SLAMが得意な環境ばかり集まる」収集バイアスの指摘
[Wang 2026]

対策＝LiDAR等の追加センサ化 — ただし同期問題が再登場



「実機不要で安い」が、後処理が負担になってくる

YUBI : 1万時間運用の現場 (AIRoA)

UMI派生のhandheld (yubi.airoa.io)

約319g
finger-aligned設計

VRベース6DoF
SLAM依存を低減

bimanual対応

OSS / OSH公開

海外拠点で1万時間超 を収録。トヨタ・産総研と
協業 (第5回スライド準拠)

この規模で起きること


次の仕事が研究タスクではなく職種 になる (第5回・
採用スライド参照)

3Dトラッキング

映像アノテーション

キュレーション


オペレーション



データ収集は「実験」から「生産」へ。生産には品質管理部門が要る

ケース② egocentric : 行動ラベルの無いデータ

第5回の到達点 : Ego4D (3,670h) / EPIC / Ariaは量的に豊富だが行動ラベルが無く embodiment gap
—「どう集め・橋渡すか」で終わった



橋渡しの下流 (retarget・co-training) と2026年のスケール則 (EgoScale) は付録

経路A : 収集時に姿勢を取る

デバイスの力でラベルを量産
(→ EgoDex)

経路B : 事後に推定する

野生の動画に疑似ラベルを付与
(→ VITRA / HaMeR系)

行動ラベルを作る2つの経路：EgoDexとVITRA

経路A：収集時に取る

EgoDex [Hoque+ 2025]：Vision Pro内のSLAMと校正済み多眼で、
両手25関節の3D姿勢を記録時に付与

829 時間

33.8万 ep

194 タスク

限界：遮蔽・高速動作時は姿勢も推定なので誤る

経路B：事後に推定する

VITRA [Li+ ICRA 2026]（第3回既出）：
野生の動画に 手姿勢推定（HaMeR [Pavlakos+ CVPR 2024] 等） +
カメラ軌跡推定 をかけ、疑似行動ラベルを生成

魅力：適用範囲は事実上無限

代償：ラベル品質が推定器の精度に律速される

産業採用：Qwen-RobotManip [2026] はEgoDex 732時間とVITRAを学習に投入済み（経路A・Bとも実戦配備）

脚注：橋渡しの下流（retarget・co-training）とEgoScaleのスケール則は 付録

egocentricの本質的コストは収集ではなく「ラベル付けと品質保証」 → §4の主役「ラベル品質」への伏線

ケース③ 収集は工場化された：品質管理ラインの実際

分散・標準化

DROID

13機関に同一ハード（Franka＋stereo＋wrist）とプロトコルを配布
76k軌道 / 350h / 564シーン

工場・専任

AgiBot World

100台・専任オペレータ・human-in-the-loop検証を標準工程化 100万軌道
/ 約3,000h / 217タスク

フリート

GEN-0

数千台規模の収集オペレーション
（詳細は非公開）
第5回：「何を集められる会社か」

タスク仕様書



収集



即時検品



合格 / 再収集

一流の現場は品質管理をラインに内蔵している。それでも漏れるものが §2以降の主題

必要量をどう見積もるか：データスケール則の実験



必要量はタスク・ロボット・事前学習・環境分布で大きく変わる。持ち帰るのは見積もりの実験設計と代表的なスケール感。

Lin & Hu [ICLR 2025 Oral] : UMIで4万デモ・1.5万回rollout・環境数×物体数×環境あたりデモ数を独立に振る要因分解

発見1 汎化性能は 環境数・物体数に
べき乗則 で向上

発見2 1環境あたりのデモ数は 閾値
で飽和 （多様性 >> 絶対量）

戦略多環境×少デモ : 4人×半日で
新環境・新物体に約 **90%成功**



目的で答えが変わる：単一タスクの汎化＝多様性の枚数で数える／基盤モデル＝GEN-0の27万時間が示すとおり絶対量も要る


「足せば伸びる」への反証（負の転移・5%コアセット。詳細は付録）→ 潮流は量のスケール則から質と構成のスケール則へ

小括図：収集手段×規模×品質保証の俯瞰マップ

色＝行動ラベルの作り方：

白：収集時に取得（実機・デバイスで直接） オレンジ：事後推定（SLAM等・後処理が重い）

↑
後処理距離



スループット →

§1のまとめ：収集は解けつつある。次のボトルネックは処理

- 1 集めやすさ $\Leftrightarrow$ 学習可能までの距離はトレードオフ（UMI=SLAM、ego=ラベル生成）
- 2 一流現場は品質管理をラインに内蔵。それでも規模が人手を超える（週1万時間）
- 3 量は多様性で数える（べき乗則） — ただし基盤モデルは絶対量も要る

週1万時間の生データを、誰がどうやって (o, a) にするのか？

- 1 収集の現場
- 2 生データの解剖学：生データは学習できない**
集めた直後のデータには、まだ (o, a) ペアが存在しない
- 3 データセット化
- 4 データキュレーション
- 5 可視化と検証とリプレイ
- 6 演習（Colab）
- 7 まとめ

ロボットデータはなぜ非同期か

センサ	周波数
RGBカメラ	30Hz 露光は非決定的
関節エンコーダ	100Hz～1kHz
F/T（力覚）	500Hz～
触覚	100Hz～
グリップパ指令	数十Hz

各センサ＝独立プロセスが独立クロックでpublish



→ 時刻グリッドは揃わない（ROSノードグラフ上の独立ノード）

一般的な独立センサ構成では、同じ時刻を写したデータは自然には揃わない。届く順序も保証されない

この非同期性は二度現れる：第7回との分界

一度目：記録側【本日】


bagの中の止まった時間 を、後からいくらでも眺めて揃えられる

二度目：実行時【第7回】

観測が届いた時刻と推論が終わる時刻がずれる
（ **obs timing gap** ）、action chunkの繋ぎ目、
非同期推論、RTC
— 待ったなしの時間の中で 同じ問題を解く

今日学ぶ「時刻の作法」は、来週そのまま実行時の議論の土台になる

rosvbag=topic / message / connection の **追記型ログ**
「届いたものを届いた順に書くだけ」— 取りこぼさない、
しかし整列しない



MCAP：Foxglove発の効率的コンテナ。ROS外でも汎用ログ形式として普及中

```
$ ros2 bag info episode_0042/  
Files: episode_0042.mcap (612 MiB)  
Duration: 48.2 s  
  
Topic Type Count Hz  
/cam_head/image_raw sensor_msgs/Image 1443 29.9  
/cam_wrist/image_raw sensor_msgs/Image 1439 29.8  
/joint_states sensor_msgs/JointState 9641 200.0  
/leader/joint_commands sensor_msgs/JointState 2410 50.0  
  
/gripper/command std_msgs/Float32 964 20.0
```

bagは「実験の真実の記録」であって「学習データ」ではない。この区別が出発点

2つの時刻：header.stampと受信時刻



header.stamp

センサがデータを取得した時刻
(そのノードのクロック)

受信時刻 (bag記録時刻)

メッセージが届いた時刻

伝送遅延・jitter = 数ms～数十ms、しかも揺らぐ

原則：同期は **header.stamp** で行う

落とし穴：stampの意味はドライバ依存
— 露光開始？転送完了？で **数十ms** 変わる。
自分のセンサの仕様を一度は確かめる

時刻の土台：クロック同期（NTPとPTP）

前提：header.stampが有効なのは各マシンの時計が揃っている場合だけ



精度の階段（右ほど高精度・高コスト）

実例：マシン間で時計が数百msずれたまま収集
→ **全ペアが系統的にズレた** データが量産される
（演習で体験：ずれたbagを1本仕込んであります）

ここが崩れたデータは、後段でどう頑張っても直せない — 収集システム設計の時点で決まる品質がある

同期アルゴリズム①：ExactTime

ROS `message_filters` の厳格方式：全topicのstampが完全一致した組だけ採用




適用場面：ハードウェアトリガで同期した多眼カメラ
(stampが本当に一致する場合)

弱点：一致しなければ**全部捨てる**
→ ソフトウェア収集のデータではほぼ何も残らない

同期アルゴリズム②：ApproximateTime（実務の主役）

方針：各topicのキューから 時刻の広がりが最小になる組を貪欲に選ぶ（許容窓＝**slop**）



```
for t in reference_stamps:
    picks = {}
    for topic in others:
        j = argmin |topic.stamps - t|  # 最近傍
        if |topic.stamps[j] - t| > slop:  # 窓外
            break  # この t は組ごとと棄却
        picks[topic] = j
    else:  # 全topicが窓内のときだけ
        emit(t, picks)
```

slop＝「観測の同時性をどこまで妥協するか」のノブ
 狭い→データが減る／緩い→質が下がる。
 演習で自作&感度を測る




1kHzの関節角と30Hzのカメラを、学習用固定fps（例：30Hz）のグリッドへ整列 — 実務はカメラを基準クロックに

信号の種類	補間法	理由
低次元連続量 関節角・EE pose	線形補間 or 最近傍	滑らかに変化する物理量
画像	最近傍	補間不可 — 実務はカメラ自体を基準クロックに
離散量 グリッパ開閉	ゼロ次ホールド	前の値を保持（中間値は存在しない）

注意①：ダウンサンプリング時のエイリアシング

注意②：補間は「**実在しなかった値**」を作る操作
— 1kHz→30Hzで振動情報は消える

actionを作る：観測と指令の対応付け



なぜ「未来」か：テレオペでは人の指令が観測より先を行く／実機の追従には遅れがある
— 対応付けの Δ 自体が設計パラメータ

今日は素材（正しい $(o, a_{t:t+k})$ ）を作るところまで。
実行時にchunkをどう繋ぐか（stall・繋ぎ目の不連続）は第7回

フレームドロップ




カメラが一瞬止まる
→ その区間は **棄却が原則**。補間で埋めると「見ていないもの」を捏造

stampの巻き戻り・重複



ドライバ再起動・bag分割境界で発生
→ **単調性チェック必須**

クロックずれ



マシン間で数百ms
→ **全ペアが系統的にズれる**
(スライド26)

共通点：どれもエラーを出さない。データは正常な顔でパイプラインを通過する

時刻ずれは方策を壊しうる：何msからかを演習で測る

意味系の落とし穴：stampの意味のドライバ依存（露光か転送か）／テレオペ指令と実機追従値の取り違い（stateとactionの混同）

観測と行動がずれたデータでは、 $\pi(a|o)$ は「少し過去を見て動く」写像を学習する。
教師データ内では辻褃が合うため学習lossは普通に下がる。壊れるかどうかは実機でしか分からない。

用量反応（演習の実測）

lift・小型ACT：

ずれ0ms→**80%**／100ms→74%／200ms→**56%**

放置すると崩壊

can・ACT 200k step：

350msのずれを放置 → 88%が22%に

含意：許容できるずれ幅はタスク・制御周期・方策に依存する。「何msまで許すか」は思い込みではなく
測って決める設計変数（=Step 2のslop）

第3回「lossは下がるのにdeployで暴れる」の正体の筆頭 — 鉄則：デバッグは学習後ではなく、データ段階で

1 収集の現場

2 生データの解剖学

3 データセット化：学習可能な形式へ

同期された時系列を、共有でき・何年も再利用できる「資産」にする

4 データキュレーション

5 可視化と検証とリプレイ

6 演習（Colab）

7 まとめ

何を保存するか : (o, a) ペアとメタデータ

中核 : (o, a) ペア (第3回再掲)

```
obs = {  
  "image_head": (H,W,3), "image_wrist": (H,W,3),  
  "joint_pos": (7,),  
}  
action = (7,) # chunk: (k,7)
```

本日の追加要素 : メタデータ

episode境界・成功/失敗フラグ

タスク指示文 ← §4で主役に

fps・タイムスタンプ

カメラ校正・座標系

収集メタ (日時・場所・オペレータID・デバイスID)

指示文もオペレータIDも、§4で品質分析の手がかりになる — メタデータは未来の品質調査への保険

actionの定義を書く：半年後の自分は他人



action[7] = ?

目標関節角（絶対, rad）？

関節速度？

EE pose (xyz+rpy) ？

EE delta ？

グリップ＝幅？

開閉フラグ？

info.jsonに書いていなければ、
データは読めない暗号になる

チェックリスト（作ったその日に埋める）

- ☐ 単位（rad / deg ・ m / mm）
- ☐ 座標系（base? world? camera?）
- ☐ 絶対 or 相対（delta）
- ☐ グリップ表現（幅 / フラグ）
- ☐ 正規化の有無・統計

```
my_dataset/  
├ meta/  
│ ├── info.json # fps・特徴量定義  
│ ├── stats.json # 正規化統計  
│ └─ tasks.parquet  
├ episodes/  
│ └─ data/chunk-*/file-*.parquet  
└─ # 低次元時系列（複数ep連結）  
    └─ videos/<cam>/chunk-*/file-*.mp4
```

三層の役割分担

状態・行動

= **Parquet**（列指向）

映像

= **MP4圧縮**

意味情報

= **メタデータ**
（fps・定義・統計・指示文）

第3回のColabで使ったデータもこの形式。
一度この図と見比べておくと、以後どのデータセットを開いても迷わない

エピソード毎ファイル → チャンク連結

ファイル数激減 → OXE級規模でファイルシステムが死なない

StreamingLeRobotDataset

Hubからダウンロードなしで学習。メタデータはparquetに統一

delta_timestamps

過去観測・未来行動（action chunk）を 宣言的に取得

トレードオフ例：

画像→MP4で容量1～2桁減 ⇔ ランダムアクセスに デコードコスト

フォーマット設計＝トレードオフの取引の集合

OXE型統合の不整合の実例

観測：視点・解像度・色空間の違い

行動：EE delta? 絶対pose? 関節角? 単位・座標系・グリッパ表現の違い

— 同じ action[7] でも中身が別物

fps：3～30Hz混在

スライド35の問題が60データセット分存在する


DROIDのfeature定義（porting docsより）

```
action_dict/  
  cartesian_position (6,)  
  cartesian_velocity (6,)  
  joint_position (7,)  
  joint_velocity (7,)  
  gripper_position (1,)
```

cartesian / joint / gripperを併記
= 下流に選択を委ねる設計

統合とは、意味の翻訳作業

データの系譜：rawを上書きしない、工程を再現できる



最低限の規律

☐ raw dataは上書きしない

☐ 変換コードと設定をバージョン管理

☐ schema versionを持つ
(スライド35のaction定義とセット)

☐ 除外したepisode IDと理由を残す

☐ manifest (dataset card・checksum) で同じデータセットを再生成できる状態に

§4の判断表（演習）とスライド55「ログのないキュレーションは気分」の土台 — 系譜のいちばん小さな単位が判断表



フォーマットに従うことは不自由ではなく、エコシステムへの接続

- 1 収集の現場
- 2 生データの解剖学
- 3 データセット化
- 4 データキュレーション：量から質へ**
そのエピソード、本当に学習させて良いですか？
- 5 可視化と検証とリプレイ
- 6 演習（Colab）
- 7 まとめ

何が「良いデータ」か：品質の4分解 （概念的な分解。実証された数式ではない）



本節の主演＝後ろの2つ

対処は削除だけではない：filter／重み付け／relabel／condition／追加収集（→ 本節後半）

4つは掛け算 — どれか一つがゼロなら、他が満点でも価値はゼロに近づく

robomimic [Mandlekar+ CoRL 2021]

複数オペレータの混在品質デモを体系比較

→ 質の混在は性能を大きく損なう

Better / Okay / Worse オペレータの分析


理論的定式化 [Belkhale+ NeurIPS 2023]

action divergence (expertと学習方策の行動分布のずれ)
＝模倣の失敗を定量化

transition diversity (遷移の多様性・ノイズ由来含む)
＝頑健性に効き得る

BCの性能限界をデータ性質で説明

	Square				Can			
	PH	Better	Okay	Worse	PH	Better	Okay	Worse
Success Rate	58	36	12	2	96	56	40	22
Dataset Size (N)	200	100	100	100	200	100	100	100
Action Variance	0.073	0.062	0.099	0.061	0.051	0.066	0.079	0.063
Horizon Length (H)	150	190	250	350	115	140	180	300
State Similarity	8.2e-5	1.8e-4	1.7e-4	1.2e-4	1.0e-4	2.1e-4	2.4e-4	2.0e-4



「とりあえず全部学習」は、良いデモの価値を悪いデモが薄める

品質はなぜ壊れるか：収集現場のエラー分類

失敗rollout：把持ミス・落下（成功フラグ無しだと混入）

停滞・冗長：オペレータの迷い・静止区間・不必要な低速

衝突・危険動作

センサ異常：遮蔽・ドロップ・露出破綻
（§2の時刻系とは別種の破損）

指示ラベル誤り：pick⇔place取り違い・対象物の誤記 ← 後半の主役

上の4つ：行動が悪い

最後の1つだけ：行動は正しい

この違いが検出難易度を分ける

本節は二部構成：

前半＝行動品質（S46～48）

後半＝ラベル品質（S49～54）

人手QAの限界：検品ラインを通過してくるもの

§1再掲：AgiBot Worldはhuman-in-the-loop検証を標準工程化（一流現場の姿）— それでも残る限界が2つ

限界1：規模


100万軌道・週1万時間を人が 全件見ることは物理的に不可能 → サンプルング検品に

限界2：見た目の正常さ

ラベル誤り・微妙な時刻ずれ・「惜しい失敗」は再生して見ても気づきにくい

帰結：人手QAの上に「自動キュレーション」の層が要る → 研究地図へ

手法サーベイの地図：2軸による分類



出典) Hejna+ CoRL 2024 (Re-Mix) / Hejna+ RSS 2025 (DemInf) / Zhang+ 2025 (SCIZOR) / Chen+ RSS 2025 (Demo-SCORE) / Agia+ CoRL 2025 (CUPID) / Dass+ 2025 (DataMIL)

ReMix [Hejna+ CoRL 2024]

dataset粒度 (§3で言及)

混合比の分布ロバスト最適化

(負の転移とABot-M0の実務は付録)

DemInf [Hejna+ RSS 2025]

trajectory粒度

相互情報量 推定で状態-行動の結びつき

= デモ品質をスコア化。教師なし・rollout不要。

robomimicの品質ラベルとよく整合

SCIZOR [Zhang+ 2025]

state-action粒度

自己教師で失敗遷移と重複・冗長区間 を除去。「エピソードの中の悪い区間だけ」削れる。RT-X混合でReMix比 **+3.5%**

共通の強み : rollout不要でスケールする

弱み : 閉ループ性能との直結は保証されない

Demo-SCORE [Chen+ RSS 2025]

policy rolloutの成否から分類器を学習

→ 「再現できるデモ」を残す

CUPID [Agia+ CoRL 2025]

影響関数で「そのデモが方策の
閉ループ期待リターンに与える因果的
寄与」を推定

→ 有害デモの除去／新規収集分の選別

DataMIL [Dass+ 2025]

datamodels : 回帰でデータ
→ 性能を直接モデル化

重要知見（CUPID） : 品質最高のデモ群（DemInfが選ぶ）を学習しても、CUPIDが選ぶ「寄与するデモ」に勝てない場面がある — 人が見た品質 ≠ 方策性能への寄与
(綺麗なデモが脆い戦略を誘発／spurious correlationの除去)

2026年 : 影響関数系は第2世代（QoQ＝推定精度の改善・ATHENA＝313×の高速化）で、billion級VLAの実用規模に達した（発展付録A7）

品質という直感は当てにならない、だから測る — データ中心ロボティクスの姿勢

出典) Chen+ RSS 2025 (Demo-SCORE) / Agia+ CoRL 2025 (CUPID) / Dass+ 2025 (DataMIL) / Lee+ 2026 (QoQ) / Xu+ 2026 (ATHENA)

見落とされてきた軸：ラベル品質 — 指示ラベルの誤り

ここまでの手法は全て「行動が悪いデータ」狙い — もう一種類ある

指示ラベルの誤り (instruction label noise)

= 軌道は行動として正しいが、対の 言語指示が意味的に誤り

pickのデモに

「place」

「オーブンを閉める」に

「開ける」

対象物の取り違い

bottle ⇔ mug

発生源：テレオペ現場のタスク読み違い／収集管理システムのバグ／一括アノテーションの系統誤り
— スケールした収集現場ほど構造的に混入

指示ラベルの誤りはなぜ危険か：フィルタを素通りし、言語を汚染する

① フィルタ素通り

映像・行動として もっともらしい
→ 実行品質フィルタ（DemInf等）
を素通り

② 言語→行動を直接汚染

言語条件付き方策（VLA）の教師
信号が汚染
—「置き」と言われて掴む方策に

③ 系統的に混入

ラボ横断・多拠点でスケールする
ほど混入

一般MLの先行研究：

Confident Learning [Northcutt+ JAIR 2021]
Deep kNN [Bahri+ ICML 2020]
LEMoN [Zhang+ ICML 2025]

ロボット特有の条件：

マルチモーダル（複数カメラ＋関節）で、しかも **どのモダリティも
時々死ぬ**（遮蔽・ノイズ・タスク依存の無情報性）
→ 単一視点に頼れない

この条件に合う監査器が要る

ラベルを「作る」研究 vs 「監査する」研究

生成・付与する側

DIAL [Xiao+ RSS 2023] : VLMで指示を増強

NILS [Blank+ CoRL 2024] : 基盤モデルでゼロショット付与

CLIP-RT [G.-C. Kang+ RSS 2025] : 自然言語監督の生成・relabel

CAST [Glossop+ 2025] : 反実仮想ラベル を足して指示追従を改善

監査する側

生成側の規模 : EgoScale 2万時間の疑似ラベル／
GR00T Blueprint 78万本の合成ラベル ラベル済み（人の労力が入った）データセットの **誤りを検出・訂正**
先行はほぼ一般ML（Confident Learning / LEMoN）のみ
ロボットではほぼ未開拓＝open problem

補完関係：生成側がスケールするほど「生成されたラベルの品質保証」が必要
— 監査は生成の相棒（future work：自動ラベル生成×監査の統合）

古典的な道具はどこまで効くか：埋め込み空間でのラベル監査

Deep kNN [Bahri+ ICML 2020]

埋め込み空間の近傍のラベル投票と
自分のラベルが食い違う点を疑う


最近傍セントロイド (プロトタイプ)

クラスごとの中心ベクトルに最も近い
クラスと付与ラベルの食い違いを疑う

Confident Learning [Northcutt+

JAIR 2021]
分類器の予測確率からラベルノイズ率
を推定。

実装は cleanlab (pip一発)



適用の勘所：軌道を1本のベクトルにする埋め込みが要る

演習ではDINOv2のフレーム特徴（16フレーム×384次元）を、
順序を残してプーリングした事前計算済み配布（平均プーリング
だと往路と復路が同じ点に潰れる）。
動画基盤の軌道埋め込みはその発展形

教科書的な公開技術だけで、ラベル監査の第一歩は踏み出せる — 演習で自分の手で動かす

しかしロボットには固有の困難がある：未解決の研究問題

① 多視点の不一致

頭部カメラ・手首カメラ・関節系列で「
見えているもの」が違う。

どれを信じるか

② モダリティが時々死ぬ

遮蔽・ノイズ・タスク依存の無情報性（関
節系列は物体の状態を知らない）。

単一視点の判定は簡単に外れる

③ 閉ループへの影響が未検証

検出したデータを消すのと直すのとで、
下流の方策性能がどう変わるか
（→次スライド）

隣接研究：LEMoN [Zhang+ ICML 2025] はマルチモーダルなラベルエラー検出（画像キャプション向け）

— ただし 軌道×多センサの設定は直接扱っていない

スライド46の分類で空欄だった象限は、2026年時点でほぼ未開拓

Filtering vs Relabeling vs Conditioning : 捨てるか、直すか、条件付けるか



Filter（捨てる）の副作用

データ量が減り、低レベル制御のカバレッジが痩せる
（robomimicの知見の裏返し）。フィルタは分布も歪める。

演習Step 5で実測：worseを捨てた③（54%）が、残した②（88%）に負ける

Relabel（直す）の価値

軌道という高価な資産を保全。VLMによる指示の再付与・増強で下流性能が上がることは公開研究が示す（DIAL [Xiao+ RSS 2023]・NILS [Blank+ CoRL 2024]・CAST [Glossop+ 2025]）

ただし不正確な訂正は害（誤ったラベルを上書きで増やす）→ 確認してから直す

第3の選択肢：Condition（重み付けて全部使う）： $\pi*0.6$ のRECAP [PI, 2025-11]

— 失敗を含む経験に advantage（価値の増分）を条件付けして学習、実行時に高advantage側を指示
→ 悪いデータも「何が悪いかの情報」として使い切る

原則：軌道が壊れていればfilter、軌道が有効でラベルだけ疑わしければ確認のうえrelabel

— 有効な軌道は資産、ラベルは修理可能な部品

キュレーション実務の階段：目視、統計、自動化

～数百エピソード

全件目視（rerun）＋リプレイ
最強かつ十分

～数万

統計スクリーニング（長さ・行動分布の外れ値・静止区間検出）
＋サンプリング目視

それ以上

埋め込みベース自動監査
（DemInf / CUPID / kNN系ラベル監査）
＋人手は検出結果の確認に集中

規律1：

何を消したかのログを残す — フィルタは分布を歪める
（難しい状況のデータばかり消える等）。

置き場所は§3のデータの系譜（スライド39）

規律2：

一回のバッチ処理ではなく評価とセットのループにする

ログのないキュレーションはあとで後悔する

- 1 収集の現場
- 2 生データの解剖学
- 3 データセット化
- 4 データキュレーション
- 5 作ったデータを確認する：可視化、検証、リプレイ**
パイプラインを通ったことと、正しいことは別
- 6 演習（Colab）
- 7 まとめ

Foxglove

bag / MCAP段階 — 収集直後の一次チェック

bag/MCAPをブラウザに投げてそのまま再生（**ROS不要**）。
全topicのタイムライン・3D・プロット

rerun

データセット化後

LeRobot公式ビューワの中身。
時系列＋カメラ＋状態・行動の **同期スクラブ**。
HF Spaces「Visualize Dataset」でHub上の任意データセットを
閲覧

目視の一点集中ポイント：グリッパが閉じる映像の瞬間と、閉指令の立ち上がり の一致
＝ §2の同期の検算

統計的チェック：静かな不具合を見つける

□ エピソード長分布

極端な長短＝停滞・途切れ

□ 行動の各次元の分布・レンジ

単位ミス・スパイクが一発で見える

□ Δt （タイムスタンプ差分）分布

ドロップ・jitter残存

□ タスク別エピソード数

不均衡

□ stats.json（mean/std）の妥当性

正規化統計が壊れると学習全体が静かに壊れる

目視は深いが狭い。統計は浅いが全部見る — 相補的に使う

データ分割とリーク：評価を過大にしない

ロボットデータの罫：隣接フレームはほぼ同一、同一環境の軌道は酷似
→ frame単位のランダム分割は、trainとtestに「ほぼ同じデータ」を配る（リーク）

分割の単位（下ほど厳しい評価）

episode単位（最低限）

operator単位／collection date単位

object instance単位

environment単位

robot embodiment単位

何を主張したいかで単位を選ぶ

未知環境への汎化を主張するなら**environment単位**で切る。
§1のスケール則研究が環境と物体で分割したのはこのため。
今日の演習データもepisode単位で分割済み。

検証（§5）は、データの正しさに加えて、評価が信じられる形かも確かめる工程

実機リプレイ：最も確実なサニティチェック

原理：データセットのaction列を方策を介さずそのまま実機へ（lerobot-replay）
—「データが正しければ、ロボットはタスクをもう一度成功させるはず」

リプレイで露見（学習では隠れる）

単位・座標系・関節順序の取り違い

校正ズレ

action定義の誤解（絶対 / 相対）

fps不一致（再生速度）



学習ゼロ回・数分の簡易統合テスト（方策側の評価設計は第7回へ）

data flywheel : 工程はループする



↪ 実走行ログ・失敗データが次の収集へ戻る

環流の製品化 : $\pi*0.6$ / RECAP [Physical Intelligence, 2025]

デプロイ中の①自律経験（スパース報酬つき）②人の介入補正を回収して再学習

→ エスプレッソ 13時間以上連続稼働・洗濯物50点・工場で箱組立59個。難タスクでスループット2倍・失敗率1/2以下

flywheelは2025年までは概念図だった。2026年、この仕組みは実運用される現実のシステムとなった

出典) Physical Intelligence 2025 ($\pi*0.6$ / RECAP)

演習：汚れたbag 16本から、学習可能なデータセットを納品せよ

進め方（一方通行）：講師がノートブックを映しながら上から順に実行
→ 各自のColabで同じセルを同じ順に実行して結果を確かめる

ミッション bag 16本（本物の人間のテレオペ）を
LeRobotDataset で納品。
ただし講義で学んだ問題が数本混入。
keep / filter / relabel を判断し、根拠を書く

ノートブックの作法 穴埋め（#TODO）
→ 直後に**解答セル**（詰まったら開く）
各Step末に**checkpoint**（追いつき用） **CPUでOK**
（GPUは発展Step6のみ）

Step 0 準備



1 Inspect



2 Sync



3 Format



4a Curate



4b 監査



5 学習比較



6 発展

Step 0 : 環境とColabの作法



Colabの作法（3行）

- ① ランタイムは**CPU**のまま でOK
- ② 先に「ドライブにコピーを保存」
- ③ 警告は「このまま実行」を選ぶ

⚠ **robomimic**は入れない（依存がlerobotと衝突し環境が壊れる）

0-2 インストール（Colabのみ・約1分）

```
!pip install -q "rosbags>=0.10.9" \ "lerobot==0.5.1" "robosuite>=1.5,<2"
"mujoco<3.10"
```

0-3 データDL（約60MB）

```
import utils DATA = utils.fetch_data()
```

0-4 セットアップ確認

```
utils.check_step0() # → OK で準備完了
```

utils.py が裏方を全部持つ。各自 check_step0() で OK を確認してから次へ

Step 1 : Inspect — 生データの解剖（5分）

渡されたbagを信じずに確かめる：トピック構成・実効周波数・タイムスタンプの姿

```
# 1-1 全bagのトピック表 utils.topic_table()
```

```
# cam×2=20 / joints=50 / action=20 Hz
```

```
# 1-2 【TODO-1】 タイムスタンプ散布図
```

```
t_rel = stamps - cam_agent["stamp"][0] # 相対時刻
```

```
# 1-3 median(stamp - 受信時刻)[ms]
```

```
utils.latency_table() # 大きく+にずれるbagは？
```

目撃するもの

- ・カメラはまばら／関節は密
 - = 非同期 ・正常なら stamp - recv はわずかに負
 - ・1本だけ大きく正にずれる bag
 - = クロックずれの原因
 - （メモして Step4 で使う）
- 最後に `check_step1()` で足並みを揃える

気づきを1行メモ：「bag ____ が変。根拠： Δt / レイテンシ / 実効Hz」

Step 2 : Sync — ApproximateTimeを自分で書く (8分)

カメラのフレーム時刻を基準に「一番近い時刻のメッセージ」を拾う（指令＝最近傍／関節＝線形補間・範囲外は捨てる）

2-1 【TODO-2】 最近傍マッチ（本丸）

```
def nearest(stamps, t, slop):  
    i = np.searchsorted(stamps, t)  
    candids = [j for j in (i-1, i) if 0<=j<len(stamps)]  
    best = min(candids, key=lambda j: abs(stamps[j]-t))  
    return best if abs(stamps[best]-t)<=slop else None  
# 窓外→捨てる
```

TODO-3 : slop {5,20,100}ms を掃引して
採用率を見る

狭い→減る／広い→質が下がる

2-4 物理で裏を取る : 指令と関節応答の
相互相関 で実効ずれを推定
(stampを信じない検出)

考察2問 : ①slopのトレードオフは？ ②slopゲートで検出できない汚れは？ どう処置する (keep/filter/relabel) ?
→ checkpointで全員同期

Step 3 : Format & Visualize — LeRobotDataset化と検算（5分）

同期済み配列 → LeRobotDataset。今日のデータは関節7次元+OSCデルタ指令7次元（第1回のEEFとは中身が違う）

3-1 【TODO-4】 features辞書を埋めて3本変換

```
features = {  
    "observation.images.agentview": {  
        "dtype": "video", "shape": (240, 320, 3), ...  
    },  
    "observation.state": {  
        "dtype": "float32", "shape": (7,), ...  
    },  
    "action": {  
        "dtype": "float32", "shape": (7,),  
        "names": ["dx", "dy", "dz", "drx", "dry", "drz", "grip"]  
    },  
}
```

3-2 動画で検算（唯一の確認点）

グリッパ閉指令の立ち上がりと映像の 掴む瞬間
が一致？ ずれたら同期を疑う

3-3 全16本の統計ダッシュボード エピソード長

・ jerkでおかしいbagが浮かぶ
→ Step4の判断表へ

授業内は3本だけ変換（全16本はcheckpointで供給） → 授業内ゴールはここ + 判断表1行

Step 4a : Curate — 判断表を書く（3分＋随時）



処置	意味	使いどころ
keep	そのまま納品	問題なし
filter	除外して納品	直せない汚れ（同期不能・欠落・低品質）
relabel	ラベルを直して納品	データは良いのにラベルだけ違うとき

```
df.loc[6, ["decision","method","reason"]] = ["filter","latency","joint stamp +348ms"] # 例
```

「成功しているが下手」は keep か filter か
一正解は一意でない。根拠を書けることが評価軸／適用して納品物その1を作る

Step 4b : 埋め込みkNNによるラベル監査（講師デモ）

全検査（レイテンシ・ギャップ・長さ・jerk）を通ったのに、まだ2本おかしい — 統計は正常。誤りは 指示ラベルと行動の
対応（instruction label noise）

4-6 【TODO-5】 leave-one-out kNN多数決

```
np.fill_diagonal(D, np.inf) # 自分を近傍に入れない  
nn = labels[np.argsort(D[i])[:k]] # 近いk本  
pred.append(多数決(nn)) suspects = ids[pred != labels] # 容疑者
```

Deep kNN [Bahri+ 2020]／プロトタイプ：付与ラベルと食い違う点を疑う（事前計算済みDINOv2特徴を配布）


容疑者を目視 → 映像がcanなのに指示文がlift → **relabel**して納品物を完成

多視点のどれを信じるか・モダリティ欠損は ロボットでは未開拓の研究課題

Step 5 : 学習比較 — 納品物の答え合わせ（4分・閲覧中心）



同じ方策（ACT）・同じ学習規模（200k step）でデータだけ変えた3条件（can・事前計算済み・各50 rollouts）



見どころ①：①でもlossは普通に下がる。
「学習が回る」と「ロボットが動く」は別

見どころ②：③が②に負ける。
「捨てるべき」の直感が実測に裏切られる（filterの副作用）

relabelは今日のACTの成功率には効かない
（言語指示を入力に使わないため。VLAなら効く）

原則：捨てる前に副作用を測る — 処置の正しさはタスク・規模・方策に依存する

Step 6（発展）：同期ずれは何msから方策を壊すのか

発展（自宅）



⚠ ここだけGPU（T4）が必要（ランタイム→タイプ変更→T4）。自分で学習して「データ品質→成功率」を1本つなげる

最小構成：lift（約2.5秒）・デモ20本固定・96×96・小型ACT・5000 step
品質ノブは1つ：観測と行動を何msずらすか $\in \{0, 100, 200\}$ データ各1MB／学習 T4で約10～12分／3条件から1つ選ぶ

ずれ	0ms	100ms	200ms
講師の実測（各100 rollouts）	80%	74%	56%

```
# 6-1 条件を選んで学習
SHIFT_MS = 0 # @param [0,100,200]

# 6-2 評価（10 rollouts）
rate = rollout(ckpt, task="lift", n=10)
```

200msは約24pt低下（有意）／100msは約6pt（誤差） — クラスで持ち寄ると用量反応カーブが見える

演習のまとめと、さらに遊びたい人へ

今日つくったもの : bag → 同期 → LeRobotDataset → 検証 → キュレーション = 講義の全工程を1周

発展課題

- 1 Step 6のミニ実験を1条件やる。友人と条件を分担して0/100/200msの3点カーブを埋める
- 2 自分のルールでフルデータをキュレーション→再学習。
閾値（長さ・jerk・レイテンシ）を適用し、講師の②（88%）を超えられるか
- 3 D1のbagをオフセット推定で「救って」再同期し、学習に加えると成功率は上がるか

このノートブックは、研究室のデータ整備にそのまま流用できる



データスケールとは収録時間を増やすことではない。単位コスト当たりに、同期され・多様で・正しくラベル付けされ・検証可能な軌道をどれだけ作れるか。

(収集=速さ／同期=正しいペア率／形式=資産化／キュレーション=何を学習させるか／検証=判断の信頼)

1. 収集はスケールし始めた。次の律速は処理

— 集めやすい手段ほど後処理が重い (UMI=SLAM・ego=ラベル生成)。量は多様性で数える (べき乗則)

2. (o,a)ペアは同期処理が作る — 1フレームのずれはlossに現れず実機で暴れる。

良いデータ = 量 × 多様性 × 実行品質 × ラベル品質。有効な軌道は資産、ラベルは修理可能な部品 (filter vs relabel vs condition)

3. 検証までがデータづくり — 可視化・統計・実機リプレイ。工程はflywheelとして回る

本日＝記録側の非同期 bagの中の止まった時間を揃える

第7回＝実行時の非同期 obs timing gap・非同期推論・action chunkの繋ぎ目・RTC、そして評価とシステム

flywheel再掲：第7回のデプロイが生む**実走行ログ**＝本日の工程への次の入力
—「データ収集・学習・評価の一連のシステム」が次回で一周して閉じる

ありがとうございました

収集プラットフォーム・スケール則 (§1)

- C. Chi et al., "Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots," RSS 2024.
- T. Ohkawa, J. Arima et al., "YUBI: Yielding Universal Bidigital Interface for Bimanual Dexterous Manipulation at Scale," arXiv:2606.10244, 2026. (yubi.airoa.io)
- Z. Wang, "UMI-3D: Extending Universal Manipulation Interface from Vision-Limited to 3D Spatial Perception," arXiv:2604.14089, 2026.
- R. Hoque et al., "EgoDex: Learning Dexterous Manipulation from Large-Scale Egocentric Video," arXiv:2505.11709, 2025.
- S. Kareer et al., "EgoMimic: Scaling Imitation Learning via Egocentric Video," ICRA 2025.
- Q. Li et al., "Scalable Vision-Language-Action Model Pretraining for Robotic Manipulation with Real-Life Human Activity Videos" (VITRA), ICRA 2026.
- R. Zheng, D. Niu, Y. Xie et al., "EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data," arXiv:2602.16710, 2026.
- A. Khazatsky et al., "DROID: A Large-Scale In-the-Wild Robot Manipulation Dataset," RSS 2024.
- Q. Bu et al., "AgiBot World Colosseo: A Large-scale Manipulation Platform for Scalable and Intelligent Embodied Systems," IEEE T-RO, 2026.
- Generalist AI, "GEN-0," 2025. (<https://generalistai.com/blog/gen-0>)
- F. Lin, Y. Hu et al., "Data Scaling Laws in Imitation Learning for Robotic Manipulation," ICLR 2025.
- Y. Wang et al., "Rethinking Visual-Language-Action Model Scaling: Alignment, Mixture, and Regularization," arXiv:2602.09722, 2026.
- K. Chen et al., "FT-NCFM: An Influence-Aware Data Distillation Framework for Efficient VLA Models," arXiv:2511.16233, 2025.
- T. Fang et al. "SEVO: Semantic-Enhanced Virtual Observation for Robust VLA Manipulation via Active Illumination and Data-Centric Collection," arXiv:2605.11114, 2026.
- "Qwen-RobotManip Technical Report: Alignment Unlocks Scale for Robotic Manipulation Foundation Models," arXiv:2606.17846, 2026.
- AIrOA MoMa Dataset: A Large-Scale Hierarchical Dataset for Mobile Manipulation. arXiv:2509.25032, 2025.
- T. Z. Zhao et al., "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware" (ALOHA), RSS 2023.
- K. Grauman et al., "Ego4D: Around the World in 3,000 Hours of Egocentric Video," CVPR 2022.
- D. Damen et al., "Rescaling Egocentric Vision: Collection, Pipeline and Challenges for EPIC-KITCHENS-100," IJCV 2022.
- A. Miech et al., "HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips," ICCV 2019.

- K. Li et al., "ManipTrans: Efficient Dexterous Bimanual Manipulation Transfer via Residual Learning," CVPR 2025.
- NVIDIA, "SONIC: Supersizing Motion Tracking for Natural Humanoid Whole-Body Control," 2025.
- HumanNet: Scaling Human-centric Video Learning to One Million Hours, arXiv:2605.06747, 2026.

合成データ・動画生成 (§0-1)

- J. Jang et al., "DreamGen: Unlocking Generalization in Robot Learning through Video World Models," CoRL 2025.
- NVIDIA, "Isaac GR00T Blueprint for Synthetic Manipulation Motion Generation," 2025. github.com/NVIDIA-Omniverse-blueprints/synthetic-manipulation-motion-generation
- NVIDIA, "GR00T N1: An Open Foundation Model for Generalist Humanoid Robots," arXiv:2503.14734, 2025.

データ形式・大規模統合 (§2-3)

- NVIDIA, "Cosmos World Foundation Model Platform for Physical AI," arXiv:2501.03575, 2025.
- A. O'Neill et al., "Open X-Embodiment: Robotic Learning Datasets and RT-X Models," ICRA 2024.
- H. Walke et al., "BridgeData V2: A Dataset for Robot Learning at Scale," CoRL 2023.
- LeRobotDataset v3.0. Hugging Face documentation, 2025.
- rosbag. Open Robotics. <https://wiki.ros.org/rosbag>
- MCAP. Foxglove. <https://mcap.dev>
- J. Hejna et al., "Re-Mix: Optimizing Data Mixtures for Large Scale Imitation Learning," CoRL 2024.
- Y. Yang et al., "ABot-M0: VLA Foundation Model for Robotic Manipulation with Action Manifold Learning," arXiv:2602.11236, 2026.

データ品質・キュレーション (§4)

- A. Mandlekar et al., "What Matters in Learning from Offline Human Demonstrations for Robot Manipulation" (robomimic), CoRL 2021.
- S. Belkhale et al., "Data Quality in Imitation Learning," NeurIPS 2023.
- J. Hejna et al., "Robot Data Curation with Mutual Information Estimators" (DemInf), RSS 2025.
- A. S. Chen et al., "Curating Demonstrations using Online Experience" (Demo-SCORE), RSS 2025.
- C. Agia et al., "CUPID: Curating Data your Robot Loves with Influence Functions," CoRL 2025.
- S. Dass et al., "DataMIL: Selecting Data for Robot Imitation Learning with Datamodels," arXiv:2505.09603, 2025.
- Y. Zhang et al., "SCIZOR: A Self-Supervised Approach to Data Curation for Large-Scale Imitation Learning," arXiv:2505.22626, 2025.
- H. Lee et al., "Quality over Quantity: Demonstration Curation via Influence Functions for Data-Centric Robot Learning" (QoQ), arXiv:2603.09056, 2026.
- T. Xu et al., "ATHENA: Accelerated Multi-Task Heterogeneous Influence Functions for Robot Data Curation," arXiv:2606.16208, 2026.
- C. Northcutt et al., "Confident Learning: Estimating Uncertainty in Dataset Labels," JAIR 2021.
- D. Bahri et al., "Deep k-NN for Noisy Labels," ICML 2020.
- H. Zhang et al., "LEMoN: Label Error Detection using Multimodal Neighbors," ICML 2025.
- NVIDIA, "Cosmos-Embed1" (model release), huggingface.co/nvidia/Cosmos-Embed1-448p, 2025.
- G. Pavlakos et al., "Reconstructing Hands in 3D with Transformers" (HaMeR), CVPR 2024.
- M. Oquab et al., "DINOv2: Learning Robust Visual Features without Supervision," TMLR 2024.

ツール

- LeRobot documentation (LeRobotDataset v3.0, lerobot-replay). Hugging Face.
- rerun. <https://rerun.io>
- Foxglove. <https://foxglove.dev>
- ROS message_filters documentation (C++ ApproximateTime policy / Python ApproximateTimeSynchronizer). wiki.ros.org/message_filters/ApproximateTime

ラベル生成・評価環流

- T. Xiao et al., "Robotic Skill Acquisition via Instruction Augmentation with Vision-Language Models" (DIAL), RSS 2023.
- N. Blank et al., "Scaling Robot Policy Learning via Zero-Shot Labeling with Foundation Models" (NILS), CoRL 2024.
- C. Glossop et al., "CAST: Counterfactual Labels Improve Instruction Following in Vision-Language-Action Models," arXiv:2508.13446, 2025.
- Physical Intelligence, " $\pi^*0.6$: a VLA That Learns From Experience" (RECAP), arXiv:2511.14759, 2025.
- ICRA 2026 Workshop, "From Data to Decisions: VLA Pipelines for Real Robots." AIRoA. <https://icra2026vlapipeline.github.io>
- G.-C. Kang et al., "CLIP-RT: Learning Language-Conditioned Robotic Policies from Natural Language Supervision," RSS 2025.
- J. Zhang et al., "SPRINT: Scalable Policy Pre-Training via Language Instruction Relabeling," ICRA 2024.


LLM側の類推 (§0)

- J. Kaplan et al., "Scaling Laws for Neural Language Models," arXiv:2001.08361, 2020.
- N. Muennighoff et al., "Scaling Data-Constrained Language Models," NeurIPS 2023.
- C. Raffel et al., "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer" (C4), JMLR 2020.
- G. Penedo et al., "The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale," NeurIPS 2024 Datasets and Benchmarks.
- J. Li et al., "DataComp-LM: In Search of the Next Generation of Training Sets for Language Models," NeurIPS 2024 Datasets and Benchmarks.
- D. Su et al., "Nemotron-CC: Transforming Common Crawl into a Refined Long-Horizon Pretraining Dataset," arXiv:2412.02595, 2024.

発展付録

本編から外したサーベイ的トピック（配布版のみ）。各スライド右上に「発展」マーク。本編からの参照：S16（retarget/co-training・EgoScale）、S18（反証）、S47（ReMix）、S41扉（対応表）、S48（QoQ/ATHENA）

前回再掲：world model／simは実機データを増幅する中間層（GR00T dreams・第5回） — 本日は品質管理の視点で読み直す



└─ 工程の後半は丸ごと品質管理（QA） ─┘

規模：Isaac GR00T Blueprint（sim拡張系）は**11時間で78万合成軌道**＝人手テレオペ約6,500時間相当。
DreamGen系ではGR00T N1が827時間分のneural trajectories（実収集88hの約10倍）を実データと共学習

生成動画は物理的に破綻しうる／疑似ラベルは推定にすぎない → **合成はフィルタとラベルのQA問題も増やす**

UMIのSLAM歩留まりと同型 — 収集を自動化した者は、品質管理も自動化しなければならない

retarget

人の手軌道 → ロボットハンドの実行可能な行動 へ写す

第5回：ManipTrans [Li+ CVPR 2025]・

SONIC [NVIDIA 2025] 参照

課題：接触拘束の充足

co-training

egoデータと実機データを混ぜて学習

EgoMimic [Kareer+ ICRA 2025]：Ariaの人手データを実機デモと共学習し方策性能をスケール

設計の妙：収集も同じグラスで行い視覚ドメイン差を縮める



「混ぜ方」＝混合比の問題が再登場する（→ §3のReMixへ）

出典）Kareer+ ICRA 2025（EgoMimic）／K. Li+ CVPR 2025（ManipTrans）／NVIDIA 2025（SONIC）

EgoScale : egoデータにもスケール則が来た

発展



EgoScale [Zheng+ 2026] : **20,854時間** の行動ラベル付きegocentric動画（EgoDexの20倍超）。手は21キーポイント → **22自由度ロボットハンドの関節空間へretarget**

① human egoデータで **VLA事前学習**
20,854h

→ ② **54時間** のaligned human-robot
play dataで **mid-training** 人間表現をロ
ボットの感覚・制御に接地


→ ③ タスク **fine-tune**

発見 : log-linearスケール則

humanデータを増やすと検証lossが予測可能に低下し、**実機性能と強く相関** 平均成功率**+54%**・one-shot汎化

含意

最速だが最速だったegoが「スケール則を引ける」データ源に、
ボトルネックは**行動ラベルの量産体制**



出典) Zheng+ 2026 (EgoScale)

負の転移 [Wang+ 2026]：異種ロボットデータのプーリングで性能が下がる ことがある — 「混ぜれば得」ではない

コアセット蒸留 [Chen+ 2025]：蒸留合成した5%のコアセットで全量学習の85～90%の成功率
＝ 現行コーパスの大半は仕事をしていない

SEVO [Fang+ 2026]：収集プロトコルの多様化それ自体が汎化の最重要因子

量のスケール則 → 質と構成のスケール則（本編S22から参照）

問題：混合比が最終性能を左右 —
多いデータに引きずられる／小さくても質の高いドメインが埋もれる

ReMix [Hejna+ CoRL 2024]：分布
ロバスト最適化（DoReMi系）で
ドメイン重みを自動学習 — うまく
学べていないドメインを重く

位置づけ：混合比の最適化は **データセットレベルのキュレーション**
（§4タクソノミーの一番粗い粒度）

2026年のアップデート

負の転移 [Wang+ 2026]：異種ロボットデータのプーリングで性能が下がる ことがある — 「混ぜれば得」ではない

産業実装：ABot-M0 [Yang+ 2026]：OXE・AgiBot-Beta・RoboMind・Galaxea等のソース700万軌道超を整備し、
約600万軌道（UniACT・9,500時間）に統合

データセットごとに別のキュレーション戦略を設計し、embodiment偏り緩和のため AgiBot-Betaのサンプリング比
を意図的に下げた と明記

混合比は感覚ではなく、負の転移を測りながら決める設計変数になった
— §1のco-trainingでも同じ問題が待つ

対応表：隣接分野のデータ工学からロボットへ

発展



データ工学の問題	LLMでの解	動画生成での解	ロボットでの対応
重複・冗長の除去	MinHash dedup（C4以来の標準）	Cosmos Curatorのdedup段	SCIZOR（state-action粒度の類似除去）
品質フィルタ	第1世代：ヒューリスティック（C4）→ 第2世代：モデルベース分類器（ FineWeb-Edu／DCLM）	美的・動き量スコア＋VLMフィルタ（SVD, Cosmos）	第1世代：目視・成功フラグ → 第2世代： DemInf／CUPID／QoQ／ATHENA（いま移行中）
ラベル付与	（自己教師なので不要）	VLMキャプション自動生成（ Cosmos：256フレーム毎）	VLM指示生成（DIAL/NILS/CAST）。監査側は未開拓（？）
混合比の最適化	DoReMi	—	ReMix（DoReMiの直系）／ABot-M0の実務
データ枯渇への対応	data-constrained laws（繰り返し ≤4epoch）→合成データ	—	実機データが最初から枯渇 → DreamGen（合成軌道）／ego video（EgoScale）
データの価値計測	influence functions／datamodels（研究段階）	—	CUPID／DataMIL／QoQ／ATHENA（むしろロボットが先行活用）
評価→データの環流	RLHF／合成データループ	—	RECAP（ $\pi*0.6$ ）：デプロイ経験＋介入補正のRL

① 入力できる：多くの問題はLLM/動画の轍を輪郭ごと入力できる（ReMix←DoReMi、Cosmos-Embed1←動画基盤）

② 入力できない：行動ラベル（(o,a)を作る必要）・閉ループ評価（安価な代理指標なし）・embodiment

③ ロボットが先行：影響関数の実運用（ATHENA）・評価環流のRL（RECAP）—「後進分野」という見方は2026年時点で正しくない

QoQ [Lee+ 2026]

影響関数の改良：検証サンプル間の**max-influence**
採用＋軌道内集約でノイズ低減 — CUPID系の精度
改善

ATHENA [Xu+ 2026]

影響関数計算を約**313×**高速化
（Kronecker構造＋低ランク近似）
→ **billion級VLA・50タスク同時fine-tuning** で実用化
。データ **50%**（実機**66.7%**）で全量学習と同等以上

2025年に生まれた影響関数系は、2026年には「重くて使えない」段階を卒業し、実用規模に達した